


# TP558 - Tópicos avançados em Machine Learning: *A função de perda de uma GAN*



# A competição


- O discriminador,  $D$ , recebe amostras reais (do conjunto de treinamento) e amostras falsas (geradas pelo gerador,  $G$ ) e então tenta discriminar entre amostras falsas e reais.
- O discriminador é um classificador binário.
- O gerador tenta enganar o discriminador apresentando-lhe amostras similares às reais e o discriminador tenta sempre prever se as amostras são falsas ou reais.

# A função de perda min-max

$$\underset{G}{Min} \underset{D}{Max} \left[ \mathbb{E}_{(X \sim P(X))} \left[ \log D(X) \right] + \mathbb{E}_{(Z \sim P(Z))} \left[ \log (1 - D(G(Z))) \right] \right]$$

- Onde  $P(X)$  é a distribuição de probabilidade dos dados reais de treinamento e  $P(Z)$  é a distribuição de probabilidade do vetor de ruído  $Z$ . Normalmente,  $P(Z)$  é a distribuição Gaussiana.
- O gerador tenta minimizar esta função enquanto o discriminador tenta maximizá-la.
- Observe que  $D(X)$  e  $D(G(Z))$  são valores de probabilidade e ambos estão no intervalo entre 0 e 1.

# Função monotônica



- Log é uma função monotônica.
- Se uma função  $f(x)$  é monotonicamente crescente, isso significa que, à medida que  $x$  aumenta, o valor de  $f(x)$  também aumenta ou permanece constante.
- Assim,  $\text{Log}(D(X))$  é maximizado quando  $D(X)=1$  e minimizado quando  $D(X)=0$ .
- Da mesma forma,  $\text{Log}(1-D(G(Z)))$  é maximizado quando  $D(G(Z))=0$  e minimizado quando  $D(G(Z))=1$ .

# Função de perda do discriminador

$$\text{Max} \left[ \mathbb{E}_{(X \sim P(X))} \left[ \log D(X) \right] + \mathbb{E}_{(Z \sim P(Z))} \left[ \log (1 - D(G(Z))) \right] \right]$$

- Queremos que o discriminador prediga todos os  $D(X)$  como 1 e todos os  $D(G(Z))$  como 0.
- Portanto, o discriminador irá maximizar  $D(X)$  e minimizar  $D(G(Z))$  para maximizar globalmente a função de perda acima.

# Função de perda do gerador

$$\text{Min} \left[ \mathbb{E}_{(X \sim P(X))} \left[ \log D(X) \right] + \mathbb{E}_{(Z \sim P(Z))} \left[ \log (1 - D(G(Z))) \right] \right]$$

- Queremos que o gerador,  $G$ , gere amostras que enganem o discriminador de forma que  $D(G(Z))=1$ .
- Portanto, o gerador deve maximizar  $D(G(Z))$  para minimizar globalmente a função de perda acima.
- Observe que o gerador não tem controle sobre o primeiro termo, portanto o gerador minimizará apenas o segundo termo da equação.
- O primeiro termo só aparece acima para que a função seja expressa como mostrado no slide 3.

# Treinamento do gerador e discriminador

- A função de perda min-max é otimizada usando-se o algoritmo do gradiente descendente.
- Porém, ao treinarmos uma GAN não treinamos o gerador e o discriminador simultaneamente.
- Ao treinar o gerador congelamos o discriminador e vice-versa.

# Referências

- [1] “Generative Adversarial Networks”, <https://arxiv.org/abs/1406.2661>
- [2] “Understanding GAN Loss Functions“, <https://neptune.ai/blog/gan-loss-functions>
- [3] “Understanding GANs — Deriving the Adversarial loss from scratch”  
<https://medium.com/analytics-vidhya/understanding-gans-deriving-the-adversarial-loss-from-scratch-ccd8b683d7e2>